Thread Pool C++

Maurizio Terreni

Università degli studi di Firenze maurizio.terreni@stud.unifi.it

27 dicembre 2016

Sommario

Il progetto di mid-term svolge il compito di implementare una classe Thread Pool in C/C++ usando Pthreads e/o C++11. Il Thread Pool ha il compito di far eseguire ad un numero limitato di thread una queue di work, al fine di ottimizzare il throughput.

I. Introduzione

Lo scopo di un Thread Pool è quello di sottomettere dei task (work) da far eseguire al trhead pool. Sarà quindi compito del thread pool affidare il task ad un certo thread. I Thread Pool sono dotati di una coda interna di task in attesa di un certo numero di thread con cui eseguirla. Nel progetto in questione viene eseguita la regola di tipo FIFO ovvero First Input First Output (Fig. 1) in quanto il task arrivato per primo sarà in testa di esecuzione e cosi via fino al termine della queue di work. Il concetto di ricorrere all'utilizzo dei thread pool è quello di riutilizzo di un thread, infatti un thread viene riusato per far eseguire diversi task durante il suo ciclo di vita. Questo diminuisce l'overhead dovuto alla creazione dei thread e incrementa le presatazioni dei programmi che sfruttano questo tipo di concetto.




Figura 1: Esempio grafico di ThreadPool

II. TEMPO DI OVERHEAD

Lo studio del tempo di Overhead è fondamentale per individuare l eprestazioni di un sistema operativo. Esso rappresenta il tempo medio di CPU necessario per eseguire il moduli nel Kernel. Il calcolo ha la seguente espressione:

$$Overhead_{\%} = \frac{T_{CPU}perl'esecuzionedelKernel}{T_{CPU}totalediutilizzo}$$
(1)

Ovviamente più il tempo è basso, maggiore sarà la quantità di tempo CPU che si può utilizzare per i processi utente.

Nei linguaggi di programmazione ad alto livello, un esempio di overhead riguarda il tempo di esecuzione dei thread. Ogni thread infatti aggiunge il tempo necessario a gestire il meccanismo stesso di allocazione ed esecuzione del thread, questo tempo può essere ridotto utilizzando specifiche tecniche di ottimizzazione, ma non può essere eliminato del tutto. Una tecnicna utilizzata appunto è il thread pool che ci consente la generazione di un numero limitato di thread per l'esecuzione di una queue di N work in modo tale da evitare la creazione e l'allocazione di N thread.

III. IMPLEMENTAZIONE

Come possiamo vedere dal grafico UML (Fig. 2) notiamo che per realizzare il Thread Pool sono state realizzate principalmente tre classi:

- Classe Queue
- Classe Work
- Classe ThreadPool




Figura 2: Uml Progetto

i. Classe Queue

La classe Queue ha il compito di gestire la coda di task da eseguire. L'implementazione è stata realizzata tramite l'utilizzo delle code con puntatore. Analizzando il codice possiamo osservare che l'oggetto Queue è caratterizzata da due puntatori un puntatore alla testa della coda e uno al fondo della coda. Mentre la classe Node è caratterizzata da un campo data che contiene l'oggetto task e dal campo Next che è un puntatore al nodo successivo realizzando cosi la struttura concatenata (Fig. 3).




Figura 3: Esempio coda con puntatori

Listing 1: Esempio di Enqueue()

Il codice in figura mostra come avviene l'operazione di *enqueue*. Come parametro viene fornito un oggetto generico, infatti non conosciamo a priori quale tipo di task aggiungiamo, ma viene semplicemente aggiunto alla queue, sarà compito del *ThreadPool* eseguirlo in modo corretto. Una volta ottenuto il riferimento all'oggetto fornito viene eseguito un controllo sulla queue se vuota l'oggetto in questione viene aggiunto sia alla testa sia alla coda altrimenti viene concatenato.

```
T * dequeue() {
    if ( isEmpty() )
        return NULL;

    T * risu = front->data;

Node<T>* tmp = front;
front = front->next;
count--;
delete tmp;
return risu;
}
```

Listing 2: Esempio di Dequeue()

Mentre come possiamo notare nella *dequeue()* eseguiamo un controllo a priori per verificare che la coda non sia vuota, nel caso in cui siano presenti elementi viene estratto il nodo in testa e restituito al chiamante.

ii. Classe Work

```
class Work {
    private:
    int id;
    int s;
    public:
    Work(int i,int s);
    int getId();
    void doWork();
};
```

Listing 3: Classe Work

La classe Work non è altro che il task da eseguire, al momento della creazione riceve come parametri due interi, uno indica l'id del task e l'altro il tempo di sleep. Il metodo *doWork()* esegue uno sleep di *s* secondi con *s* generato casualmente nel *main* in modo da fornire

un tempimpistiche di terminazione diverse per ogni task.

iii. Classe ThreadPool

La classe *ThreadPool* ha lo scopo di eseguire tutti i task attraverso un numero limitato di thread. Come parametri gli viene fornita la queue popolata con i work e il numero di task da eseguire contemporaneamente.

```
void ThreadPool::threadPool() {
   int i = 0;
   printf("Totale Work nella queue = %d\n" , queue->size());
   for (int i = 0; i < this->numThread; ++i)
        some_threads.push_back(std::thread(&ThreadPool::managePool, this, i));
   for (auto& t: some_threads) t.join();
   printf("Totale Work nella queue %d\n" , queue->size());
}
```

Listing 4: Metodo ThreadPool()

Come possiamo vedere in figura al momento in cui viene richiamato il metodo *threadPool()* vengono generati e successivamente lanciati gli N thread. Terminato il primo ciclo *for* viene richiamato il join() su ogni thread in modo tale di essere in grado di poter aspettare la terminazione di tutti i thread prima di terminare il metodo.

```
void ThreadPool::managePool(int i) {
    while(!queue->isEmpty()) {
        mtx.lock();

        Work w = *(queue->dequeue());
        printf("Thread %d run work %d\n",i,w.getId());
        mtx.unlock();
        w.doWork();
    }
}
```

Listing 5: *Metodo ManagePool()*

Ogni Thread quindi ha il compito di prelevare dalla coda attraverso un'operazione atomica l'elemento in testa, attendere che il task sia completato e procedere con l'elemento successivo, tutto questo finchè sono presenti elementi nella coda.

iv. Classe Main

Il main come possiamo osservare nel Sequence Diagram (Fig. 4) ha il compito di generare un numero di Work associandogli un id e un tempo di terminazione casuale. Successivamente aggiunge il task alla coda popolandola cosi con i vari work da far eseguire. Una volta popolata la queue viene passata come parametro all'oggetto threadPool che avraà come




Figura 4: Sequence Diagram

compito quello di estrarre un task dalla coda ed eseguirlo.

IV. ESECUZIONE

Come possiamo vedere dall'output (Fig. 5) generato al momento dell'esecuzione abbiamo un totale di 15 task e 4 thread abilitati ad eseguirli. Al momento della generazione i 4 thread prendono i primi 4 task da eseguire stampando affianco il relativo id. Al momento in cui il work viene richiamato stampa affianco al proprio identificativo la durata in secondi dello sleep. Al termine il rispettivo thread viene liberato ed è quindi in grado di poter estrarre dalla pila il task in testa ed eseguirlo.

```
Tread Pool Terreni Maurizio Parallel Computing 2016-2017
Numero di work eseguiti contemporaneamente 4
Numero di work nella queue 15

Totale Work nella queue = 15
Thread 1 run work 1
Thread 0 run work 2
Thread 2 run work 3
Thread 3 run work 4
####### work 1 start with duration 11
####### work 2 start with duration 15
####### work 4 start with duration 13
####### work 4 start with duration 11
####### work 4 end
Thread 1 run work 5
Thread 3 run work 5
Thread 3 run work 6
####### work 5 start with duration 15
####### work 5 start with duration 15
####### work 5 start with duration 15
```

Figura 5: Output generato al momento dell'esecuzione

RIFERIMENTI BIBLIOGRAFICI

[C++ step by step] R.Lago, R.Manca, A.Monti (2004). Elemond scuola & azienda.

[Patterns for Parallel Programming]
T.Mattson, B.Sanders, B.Massingill
Addison-Wesley Professional